

Table des matières

Guide de référence pour l'annotation des expressions polylexicales verbales et nominales 2

1. Catégories annotées.....	3
1.1. Exemples des EP non annotées	3
1.2. Classification selon des critères sémantiques	3
1.3. Classification selon des critères syntaxiques	5
2. Tests linguistiques pour identifier des EP applicables à toutes les catégories d'expressions	6
3. Comment délimiter les expressions polylexicales ?	7
3.1. Délimiter les expressions verbales	7
3.2. Délimiter les expressions nominales	7
4. Pré-annotation du lexique dans la base de données PolyLexFLE.....	8
5. Annotation des textes avec INCEpTION	9
6. Test d'aiguillage vers les arbres de décision spécifiques	12
Test DIST – Identification de la distribution de la forme canonique	12
7. Références bibliographiques.....	12

Guide d'annotation pour les EP verbales..... 14

I. Tests spécifiques aux expressions verbales.....	14
II. Tests structuraux pour les expressions verbales qui permettent d'envoyer vers l'arbre de décision correspondant ...	15
III. Arbre de décision pour identifier les expressions idiomatiques verbales	15
IV. Tests pour identifier les collocations verbales.....	17
V. Arbre de décision pour identifier les collocations verbales	18
VI. Arbre de décision d'opacité	20
VII. Schéma de l'arbre de décision verbal complet.....	26

Guide d'annotation pour les EP nominales..... 27

I. Tests spécifiques aux expressions polylexicales nominales.....	27
II. Arbre de décision pour identifier les expressions polylexicales nominales.....	28
III. Schéma de l'arbre de décision nominal complet	34

Guide de référence pour l'annotation des expressions polylexicales verbales et nominales

Laboratoire LiLPa UR 1339 (Linguistique, Langues, Parole), Université de Strasbourg

Dans le cadre du projet ANR STAR-FLE, nous définissons **les expressions polylexicales** comme des séquences de mots parfois discontinues qui présentent au moins deux idiomatités statistiques, morpho-syntaxiques, syntaxiques ou sémantiques (Baldwin et Kim, 2010). Les éléments de l'EP doivent être en relation de dépendances syntaxiques (par exemple le nom est l'objet direct du verbe, ou l'adjectif est modifieur du nom).

Même s'il n'y a pas de définition unique en linguistique et en TAL, les travaux sur les expressions polylexicales s'accordent pour identifier plusieurs spécificités de ces expressions :

- **figement morpho-syntaxique** (prédilection pour une configuration morpho-syntaxique unique). Par exemple, seul le nombre singulier (*perdre **pied**, coup de **foudre***) est accepté ou un seul type de déterminant (*faire l'objet, point **de** mire*) ;
- **figement syntaxique** : les transformations de type modification, passivation etc. ne fonctionnent pas toujours : **l'objet a été fait, *pomme **noire** de terre*. Les transformations sont possibles pour certaines classes (collocations : *les décisions ont été prises*) ;
- **figement sémantique** : le sens est plus ou moins non-compositionnel (le sens global diffère de la somme des significations des éléments de l'EP) : par exemple *cheval de Troie* → le sens global (« un stratagème permettant d'introduire quelque chose de manière trompeuse ») ne correspond pas à la somme des significations des mots *cheval* et *Troie* .
- **opacité** : le sens n'est pas transparent, mais interprétable par une métaphore ou métonymie (une propriété qui est différente de la non-compositionnalité). L'opacité permet de situer les EP du totalement opaque (*rire jaune*) au complètement transparent (*pluie torrentielle*) ;
- **figement lexical** : l'expression comporte un élément qui est complètement figé dont le remplacement par un mot apparenté change le sens global (ex. *donner un coup de main* ≠ *donner un coup de **bras***, *fil de fer* ≠ *fil d'**acier***) ;

- **ordre des mots** : l'agencement des éléments est fixe et toute permutation entraîne une expression non naturelle ou un changement de sens (*faire place nette* mais pas **faire nette place* ; *hôtel-restaurant* et pas **restaurant-hôtel*).

1. Catégories annotées

Actuellement, nous annotons uniquement les expressions polylexicales nominales et verbales référentielles. Pour rappel, une expression référentielle est une forme linguistique qui donne accès à un référent du discours (Charolles, 2002), c'est-à-dire qu'elle permet de désigner de manière explicite une entité, un concept ou une situation au sein du texte. Les expressions référentielles modifiantes (adjectivales et adverbiales) ne sont pas annotées pour l'instant, bien qu'elles puissent être incluses dans des phases ultérieures du projet.

Par ailleurs, nous n'annotons pas les EP grammaticales, les pragmatèmes (Blanco Escoda et Mejri, 2018) et les EP phrastiques (parémies, proverbes, dictons), car elles présentent des caractéristiques structurelles et sémantiques différentes de celles des EP référentielles syntagmatiques.

1.1. Exemples des EP non annotées

◇ EP modifiantes (adjectivales et adverbiales) :

EP adjectivales : *rouge écarlate, grièvement blessé*

EP adverbiales : *tout à coup, de bon matin, d'un air sérieux, en un clin d'œil, très chaleureusement*

◇ EP grammaticales :

Locutions conjonctives : *bien que, dès lors que, à mesure que* ;

Locutions prépositionnelles : *au sujet de, en raison de, quant à* ;

Expressions à fonction auxiliaire : *être en train de, aller + infinitif, avoir beau*

◇ Pragmatèmes (formules figées de communication) :

À vos souhaits !, D'accord !, Bonne journée !, Merci d'avance !

◇ EP phrastiques (proverbes, dictons, parémies) :

Petit à petit, l'oiseau fait son nid ; Qui vivra verra ; Mieux vaut tard que jamais

1.2. Classification selon des critères sémantiques

Nous annotons 3 catégories d'EP, qui posent des difficultés aux apprenants du français :

- 1) les **expressions idiomatiques**, qui ont un sens non-compositionnel, résistent aux transformations syntaxiques (passivation, modification, etc.), ont au moins un élément lexicalisé (c'est-à-dire qu'on ne peut pas remplacer le mot par un synonyme ou par un mot du même champ lexical) :

- a. *prendre le taureau par les cornes* : le figement morphosyntaxique est vérifié (**prendre les taureaux par une corne*), le sens est non-compositionnel et opaque (c'est un sens métaphorique). Le remplacement d'un nom n'est pas possible sans changement de sens ou une agrammaticalité : *#prendre les vaches par les cornes / #prendre le taureau par les pieds*
- b. *jeter l'éponge* : le sens est non-compositionnel, opaque (métaphore), le figement morphosyntaxique est vérifié (changement morphologique conduit à un changement du sens : *jeter les éponges*), lexicalisé (*jeter le torchon* => changement du sens à la suite d'un remplacement d'un élément par un élément apparenté). Toutefois, certaines transformations sont possibles, par exemple passivation : *l'éponge a été jetée* ;
- c. *cheval de bataille* : le sens est non-compositionnel, opaque (métaphore). Il y a un élément lexicalisé (*cheval de bataille* ≠ *poney de bataille*, *monture de bataille* → le remplacement d'un élément par un synonyme apparenté entraîne la perte du sens idiomatique).

Les expressions idiomatiques sont difficiles autant en encodage (utilisation appropriée dans le contexte) qu'en décodage (compréhension) pour les apprenants.

- 2) les **collocations** sont caractérisées par une association lexicale forte entre un élément qui s'appelle *base* et dont le sens est indépendant du contexte, et le *collocatif* qui a un sens induit par la base. Ainsi, le remplacement du collocatif par un synonyme a comme résultat un glissement de sens. Le sens est globalement plus compositionnel par rapport aux expressions idiomatiques, mais on trouve deux sous-catégories de collocations, **les collocations opaques** (le collocatif développe un sens nouveau en fonction de la base : *rire jaune* ; *célibataire endurci*) et **les collocations transparentes** (sens compositionnel mais il y a des inférences à appliquer : *se laver les dents*, *marge d'erreur*) :

- a. *faire la fête* => le collocatif *faire* est sémantiquement vide, le sens est porté par la base, qui est le nom prädicatif *fête*. Il y a une dépendance syntaxique entre la base et le collocatif, et le remplacement du verbe n'est pas possible ou change le sens (**avoir la fête*, *#donner la fête*). Le figement morphosyntaxique s'applique aussi **faire les fêtes*. Les transformations ne sont pas toutes possibles : **La fête a été faite par Paul* ;

**Il a fait la grande fête*. Le sens est transparent (celui du nom prädicatif, le verbe est vide de sens) ;

- b. *rire jaune* => la base est *rire*, le sens du *jaune* est modifié par *rire* (ce n'est pas la couleur qui est représentée, mais à une contrainte ou une gêne), le sens est opaque et partiellement non-compositionnel ;
- c. *célibataire endurci* => la base est *célibataire*, le sens du mot *endurci* est modifié

(l'adjectif ne désigne plus celui qui est « dur, insensible », mais celui qui s'est figé dans ses habitudes avec le temps).

Les collocations sont plus facilement apprises par les apprenants en décodage (surtout pour les collocations transparentes), mais il y a des difficultés pour l'encodage.

 **ATTENTION :** Bien qu'en linguistique, la taxonomie des expressions polylexicales (EP) nominales inclue généralement une sous-catégorie dédiée aux **noms composés** — distincts des collocations et des idiomes en raison de leur fonction classifiante (Diaz Rodriguez, 2017 : 377-378) —, nous avons choisi, à l'issue d'une phase de réflexion et d'expérimentations d'annotation, de ne pas conserver cette catégorie telle quelle. Nous regroupons ainsi les **noms composés non-compositionnels** avec les **expressions idiomatiques**, et les **noms composés compositionnels** avec les **collocations**.

Cette décision repose avant tout sur une orientation pédagogique : la classification proposée vise les **apprenants de FLE**, pour qui l'enjeu principal est de **comprendre et utiliser efficacement les EP** en contexte. Dans cette perspective, il nous paraît essentiel de maintenir une **distinction claire entre collocations et idiomes**. Ces derniers posent des difficultés tant sur le plan de la compréhension que de la production, tandis que les collocations, bien que plus transparentes sur le plan sémantique, restent complexes à produire pour un non-natif (Tutin, 2013 : 40). Or, les noms composés ne constituent pas une catégorie homogène sur le plan sémantique. Comme l'indique Diaz Rodriguez, certains sont **non-compositionnels** et se rapprochent des idiomes, tandis que d'autres sont **transparentes** et comparables à des collocations (Diaz Rodriguez, 2017). Ainsi, le **critère sémantique de (non-)compositionnalité**, bien qu'important en linguistique, ne permet pas de délimiter de manière nette et fonctionnelle une catégorie autonome de noms composés dans une perspective d'enseignement. En effet, ces derniers se distribuent entre les deux pôles sémantiques précédents sans former une entité stable, identifiable avec fiabilité par un apprenant — d'autant plus que cette distinction est loin de faire l'unanimité dans la littérature linguistique.

Dans cette optique, nous considérons que **l'introduction de deux catégories supplémentaires** dans la typologie des EP nominales risquerait d'**alourdir inutilement l'apprentissage**, sans apporter de bénéfice tangible à la maîtrise du français langue étrangère. Nous faisons donc le choix de **simplifier la classification linguistique** en conservant **trois catégories seulement**, au lieu des cinq couramment identifiées en linguistique.

1.3. Classification selon des critères syntaxiques

Toutes les catégories d'expressions polylexicales sont annotées en fonction de leur **tête lexicale**, qui détermine leur comportement syntaxique. On distingue ainsi les **expressions verbales, nominales et adjectivales**, conformément aux travaux de Haussmann (1989), qui identifie des **patrons syntaxiques prédictibles** (*verbe + nom, nom + adjectif*, etc.). Ainsi, les expressions verbales doivent impérativement avoir une tête lexicale (ou base) qui est un verbe, tandis que les expressions nominales doivent apparaître dans des distributions similaires à celles d'un nom, et les expressions adjectivales ou adverbiales doivent fonctionner comme modificateurs.

Nous avons élaboré notre approche à partir des **guides développés dans les projets PARSEME et UniDive**, en y intégrant des **tests supplémentaires**.

Comme dans ces projets (ex. : <https://unidive.lisn.upsaclay.fr/>), nous proposons des **arbres de décision distincts selon chaque catégorie** (*verbale, nominale, adjectivale, adverbiale*). Par exemple, dans le projet UniDive, les expressions

nominales sont traitées à l'aide de critères spécifiques à cette catégorie (<https://parsemefr.lis-lab.fr/parseme-st-guidelines/2.0/?page=home>), et notre guide suit cette même approche en proposant un guide dédié aux EP nominales.

De plus, pour les **expressions verbales**, les tests structurels proposés par **PARSEME** orientent l'annotation vers des arbres de décision spécifiques à chaque sous-catégorie (*VID*, *LVC*, *IRV*, etc.). Dans notre cas, nous avons également défini **deux arbres de décision** : l'un dédié aux expressions idiomatiques et l'autre aux collocations (tous deux intégrés dans le guide consacré aux EP verbales).

2. Tests linguistiques pour identifier des EP applicables à toutes les catégories d'expressions

- 1) **Test du mot cranberry (test CRAN)** => si un cranberry mot (mot fossile, qui ne peut pas être retrouvé hors de l'expression donnée) est présent dans l'expression, alors il s'agit d'une expression idiomatique (ex. *prendre la poudre d'escampette* ; *us et coutumes*) ;
- 2) **Test de figement morphologique (test MORPH)** => le changement morphologique provoque un changement de sens ou une agrammaticalité => c'est une expression idiomatique (ex. *prendre le taureau par les cornes* => #*prendre les taureaux par une corne* ; *garde du corps* → #*garde des corps*) ;
- 3) **Test de figement syntaxique (test SYNT)** => les transformations syntaxiques et l'insertion de modifieurs ne sont pas acceptées (expressions idiomatiques) ou sont acceptées partiellement (collocations) => (ex. *passer l'arme à gauche* => **L'arme a été passée à gauche par lui*. – passivation impossible pour les verbes ; *étoile filante* → **étoile [très] filante* (l'insertion de modifieur impossible) ;
- 4) **Test de coordination (test COORD)** => impossible d'insérer un des éléments de l'EP dans une conjonction (ex. *Le chien me fait la fête [et des câlins]* ; **pomme [et poire] de terre*) ;
- 5) **Test de substitution des éléments lexicalisés (test LEX)** => le remplacement d'un élément lexicalisé par un synonyme conduit à un changement de sens ou à une agrammaticalité => il s'agit d'une expression idiomatique ou d'une collocation opaque (ex. *jeter l'éponge* => #*jeter le torchon* ; *eau de vie* => #*boisson de vie*) ;
- 6) **Test de non-compositionnalité (test NON-COMP)** => le sens de l'expression ne peut pas être déduit de la somme des sens individuels des composants => c'est le sens idiomatique (ex. *mettre la main à la pâte* – aucun des éléments est au sens littéral ; *cheval de Troie* – aucun des éléments est au sens littéral).



ATTENTION : Ce test repose sur une dichotomie entre sens compositionnel et non-compositionnel (et pas sur un continuum), permettant ainsi de distinguer les idiomes (dont le sens est totalement non-compositionnel) des collocations opaques (dont le sens est partiellement compositionnel).

- 7) **test de métaphore (test META)** => le sens repose sur une analogie implicite entre deux domaines sémantiques. Une telle structure reflète une opacité sémantique forte, typique des collocations opaques, sans pour autant relever d'une non-compositionnalité totale. => ainsi, l'expression *mettre la clé sous la porte* ne signifie pas qu'on pose physiquement une clé, mais qu'on ferme définitivement un commerce : l'image de la clé devient une métaphore de la fermeture définitive.

8) **test de métonymie (test METON)** => le sens repose sur un glissement sémantique par association ou contiguïté conceptuelle. Ce type d'opacité est généralement **moins marqué** que dans le cas de la métaphore, mais reste un indicateur de collocation opaque => ainsi, dans l'expression *tête d'affiche* il ne s'agit pas de la tête au sens propre, mais de la personne mise en avant sur une affiche : la partie (la tête) est utilisée pour désigner l'ensemble (la personne), ce qui relève d'une métonymie.

9) **test de restriction sémantique (test SEM_REST)** => l'expression repose sur une association régulière et préférentielle avec des cooccurrents appartenant à un même champ sémantique. Le sens est compositionnel, mais la combinaison n'est pas totalement libre : elle est stable et régulière, contrairement aux cooccurrences occasionnelles => *donner un cours / une conférence / un concert*, mais pas *#donner une chaise ; professeur de lettres / de mathématiques / de danse* mais pas *#professeur de miracle*.

3. Comment délimiter les expressions polylexicales ?

3.1. Délimiter les expressions verbales

En ce qui concerne les expressions verbales, nous faisons le choix d'annoter le verbe et les arguments lexicalisés (a priori on peut avoir des expressions discontinues). On annote seulement les éléments constitutifs de l'expression, les modifieurs ne sont pas annotés.

- Contrairement aux choix du projet PARSEME, nous incluons les auxiliaires dans l'annotation des expressions :

Exemple : *Paul [a donné un coup de main] à Marie.*

- Nous n'annotons pas les modifieurs adverbiaux :

Exemple : *Paul [a] rapidement [jeté l'éponge].*

- Nous n'annotons pas la négation :

Exemple : *Il n'[a] pas encore [passé l'arme à gauche].*

- On peut inclure la préposition si celle-ci introduit un argument :

Exemple : *être d'accord **avec**, faire l'objet **de***

3.2. Délimiter les expressions nominales

En ce qui concerne les expressions nominales, nous faisons le choix d'annoter le nom et ses modifieurs obligatoires, sans inclure les modifieurs facultatifs et les subordonnées relatives : *la [main d'œuvre] qualifiée ;*

- Le déterminant de la tête nominale n'est pas annoté, tandis que les déterminants des modifieurs de la tête nominale sont annotés : Exemple : *un [garde du corps]*

- Nous n'annotons pas les propositions relatives, dépendantes du groupe nominal annoté : Exemple : *[robots-logiciels] qui analysent les données ;*

- Nous n'annotons pas les expressions qui ont une tête lexicale pronominale et les noms propres (plus largement les entités nommées).

Exemples : *je ne sais quoi* (pronom idiomatique) ; *Tour Eiffel* (Entité Nommée).

4. Pré-annotation du lexique dans la base de données PolyLexFLE

Afin de faciliter l'annotation manuelle des expressions polylexicales dans les textes de FLE, il a été décidé de procéder à une préannotation automatique en s'appuyant sur le lexique contenu dans la base de données PolyLexFLE.

Pour rendre cette annotation automatique possible, il est nécessaire d'annoter au préalable les catégories des EP présentes dans la base, en utilisant les mêmes catégories, arbres de décision et les mêmes tests que ceux qui seront appliqués ultérieurement aux textes bruts ou préannotés.

Ainsi, les annotateurs auront accès à la base PolyLexFLE sous forme de fichier CSV. Ils devront, pour chaque expression, sélectionner :

- le type d'expression polylexicale (ex. collocation opaque/transparente, idiom, etc.) ;
- les trois tests ayant permis de l'identifier (selon l'arbre de décision correspondant).

L'attribution des trois tests sera spécifiée séparément pour les EP verbales et les EP nominales, dans les guides d'annotation dédiés à chaque catégorie.

Pour effectuer l'annotation, il suffit de cliquer sur la cellule située à l'intersection du test et de l'EP concernée, puis de cliquer sur la flèche à droite pour sélectionner une valeur dans la liste déroulante, comme illustré dans l'image 1.

Expression	Test 1	Test 2	Test 3	Type d'expression polylexicale	Exemple en contexte	Commentaires
avoir bon cœur	Test_CRAN				C'est bien un personnage qui a bon cœur, même s'il appartient à une triade.	
avoir fourbu	Test_MORPH				A part la clim qui fait un léger bruit (et je n'ai pas trouvé où la débrancher, je n'osais pas tout casser), la nuit fut bonne et le réveil brutale car la fatigue et la chaleur nous avaient fourbus.	
avoir crampon	Test_MORPHSYNT				Mademoiselle n'a jamais pu avoir beaucoup de crampon sur lui.	
avoir chaud	Test_SYNT				Ces lueurs fugaces portaient le même message : je suis là, tu n'es pas seul, on n'a plus peur, on a chaud ensemble... En dehors de la musique qui allait naître, plus rien n'existait dans ce recueillement d'attente ardente.	
avoir faim	Test_ORDRE				Les femmes et les enfants sont très fatigués et les hommes ont faim.	
avoir cours	Test_LEX				Plusieurs arrêtés autorisant à tuer le loup ont cours, dont 4 dans les Alpes de Haute-Provence et dans la Drôme.	
avoir congé	Test_MOTIV				Par exemple, si les travailleurs qui sont installés dans un campement ne peuvent pas se rendre en ville les jours où ils ont congé, que peut-on faire sur place pour promouvoir leur bien-être?	
avoir lieu	Test_NON-COMP				La Journée internationale de la démocratie, instituée par l'ONU, a lieu chaque année, le 15 septembre.	
avoir nom					Elle a nom Pocahontas (qui signifierait fille capricieuse !)... C'est du moins ce que racontera bien plus tard John Smith en quelques lignes dans son volumineux livre de souvenirs.	
avoir mal ailleurs					Il s'attendait à ce que Romain lui dise que tout allait bien et il fronça les sourcils, légèrement soucieux lorsque celui-ci affirma qu'il avait mal ailleurs.	
avoir mal nù ?					Oh ... J'arrive mon ange ... dit la jeune maman d'une voix rassurante. Tu as mal où exactement mon chéri ?	

Image 1. Annotation du lexique dans la base de données PolyLexFLE

Une fois le lexique annoté, un programme d'annotation automatique pourra être appliqué aux textes du corpus. Cette préannotation facilitera le travail d'annotation humaine à l'étape suivante. Ainsi, deux tiers du corpus seront préannotés automatiquement et les annotateurs devront alors :

- valider l'annotation proposée,
- ajouter les EP non reconnues par l'algorithme,
- ou corriger/supprimer les annotations incorrectes.

En revanche, un tiers du corpus sera quant à lui annoté intégralement à la main, sans recours à l'annotation automatique.

5. Annotation des textes avec INCEpTION

La deuxième étape de l'annotation est réalisée sur la plateforme INCEpTION, qui permet une annotation interactive ainsi que le calcul de l'accord inter-annotateurs. Pour garantir une adjudication fiable des résultats, il est essentiel de veiller à la précision de l'annotation et de suivre rigoureusement les règles décrites ci-dessous.

Nous utilisons une couche **Span_EP** (au niveau des caractères) pour identifier les éléments de l'expression polylexicale. Chaque constituant est annoté individuellement avec **Span_EP**, puis ils sont tous reliés au premier élément à l'aide des **Relation_EP**. La flèche doit indiquer la direction du premier vers chacun des autres constituants. Cette orientation est essentielle pour assurer la cohérence de l'accord inter-annotateur. Ainsi, le premier élément est marqué nominalement comme la tête de la construction, bien que cela ne corresponde pas nécessairement à la tête sémantique ou syntaxique réelle. Il est crucial d'annoter la tête et les relations afin de représenter une expression polylexicale discontinue de manière unifiée.

Pour appliquer l'étiquette **Span_EP** à un mot, il faut double-cliquer dessus. Pour annoter une relation, il faut cliquer une fois sur l'étiquette **Span_EP**, la maintenir enfoncée, puis la faire glisser jusqu'à l'autre étiquette **Span_EP** avec laquelle on souhaite l'associer.

La catégorie de l'expression est définie en sélectionnant une valeur dans la liste déroulante sous l'étiquette **label** (par exemple, **N_Colloc_transp**, **V_Idiom**). Cette procédure est illustrée par l'image 2.




Image 2. Annotation de catégorie sur INCEpTION

Au-dessus du premier élément de l'expression, les tests utilisés pour identifier l'expression et son type sont indiqués (notamment, **expression idiomatique** vs **collocation** ; **opaque** vs **transparent**). Actuellement, nous avons décidé d'en afficher deux :

- Le premier, issu de l'arbre de décision principal, permet d'identifier le type d'EP. Ce test permet de retracer l'ensemble des tests appliqués pour déterminer la catégorie dans l'arbre de décision correspondant (par exemple, TEST_CLASSQUAL permettrait de reconstituer la séquence des tests appliqués dans l'arbre de décision des EP nominales).
- Le second permet de distinguer les EP opaques des EP transparentes.

Les étiquettes des autres mots restent sans label tout en conservant l'étiquette **Span_EP**.

Pour cela, il faut sélectionner le nom du test dans la liste déroulante sous l'étiquette **ling_list** (comme illustré sur l'image 3). Cette liste permet de choisir plusieurs tests. Cependant, il n'est pas possible de conserver leur ordre d'application : INCEpTION les réorganise automatiquement par ordre alphabétique.




Image 3. Annotation de tests sur INCEpTION

Une fois l'annotation terminée, il faut cliquer sur la coche (**Finish annotation**) pour qu'elle soit visible par l'administrateur chargé de l'adjudication (comme c'est illustré sur l'image 4). À ce moment-là, le statut du document passera en **Read-only**, et il ne sera plus possible de le modifier. Tant que la coche n'a pas été activée, toutes les annotations restent modifiables.




Image 4. Marquage du document comme terminé

6. Test d'aiguillage vers les arbres de décision spécifiques

Test DIST – Identification de la distribution de la forme canonique

Le **test DIST** permet de déterminer la distribution grammaticale de l'expression candidate afin de l'annoter grâce à l'arbre de décision spécifique. L'analyse se base sur la catégorie grammaticale dominante de l'expression (à savoir la tête syntaxique de l'expression candidate).

1. Verbe, groupe verbal ou proposition verbale

Si l'expression présente une distribution syntaxique typique d'un verbe ou d'un groupe verbal, elle doit être annotée à l'aide des arbres de décision dédiés aux EP verbales (il faut donc utiliser le Guide pour les EP verbales).

Exemple : *Il a [pris la parole] lors de la réunion pour exprimer son désaccord* → *prendre la parole* a pour tête syntaxique le verbe *prendre*, ce qui confirme sa distribution **verbale**.

 **ATTENTION** : Contrairement au projet PARSEME, nous n'annotons pas les verbes pronominaux comme des expressions polylexicales. Nous les considérons comme des unités monolexicales, car leur sens est généralement dérivable de leur base verbale, même lorsque leur usage est restreint à certains contextes (se *reconvertir*, *s'effondrer*). Seuls les verbes pronominaux contenant un élément lexicalisé ou non-compositionnel (ex. *s'en mordre les doigts*) peuvent être annotés en tant qu'expressions polylexicales.

2. Nom ou groupe nominal

Si l'expression présente une distribution syntaxique typique d'un nom ou d'un groupe nominal, elle doit être annotée à l'aide des arbres de décision dédiés aux EP nominales (il faut donc utiliser le Guide pour les EP nominales).

Exemple : *Un [bourreau de travail] est celui qui travaille de manière excessive* → *bourreau de travail* a pour tête syntaxique le nom *bourreau* ce qui confirme sa distribution **nominale**.

 **ATTENTION** : Les expressions à **distribution fonctionnelle** (c'est-à-dire celles dont la tête syntaxique est un déterminant, une conjonction ou une adposition) ainsi que les expressions à **distribution modifiante** (notamment les groupes adjectivaux et adverbiaux) ne sont pas prises en compte dans le cadre du présent guide d'annotation.

7. Références bibliographiques

ANR STAR-FLE (2023-2027). *STAR-FLE – Adaptations stratégiques de textes pour mieux lire et comprendre en FLE*. Projet financé par l'Agence Nationale de la Recherche (ANR-22-CE380010). Université de Strasbourg, Laboratoire LiLPa, et Université Aix-Marseille, Laboratoire LPL. Disponible en ligne : <https://www.starfle.fr/>

Baldwin, T. & Kim, S. N. (2010). Multiword Expressions. In *Handbook of Natural Language Processing*, Boca Raton, FL: CRC Press, Taylor and Francis Group. p. 267–292.

Blanco Escoda, X. & Mejri, S. (2018). *Les pragmatèmes*, Paris, Classiques Garnier.

Charolles Michel (2002), *La référence et les expressions référentielles en français*, Paris, Ophrys.

Díaz Rodríguez, C. (2017). *Étude contrastive français-espagnol des unités phraséologiques contenant une lexie chromatique* (Thèse de doctorat). Université de Strasbourg; Universidad de La Laguna. {NNT : 2017STRAC005}.

Hausmann, F.J. & Blumenthal, P. (2006). « Présentation : collocations, corpus, dictionnaires ». *Langue française* 150, 3-13. Disponible en ligne : <https://shs.cairn.info/revue-langue-francaise2006-2-page-3?lang=fr>.

Klie, J.-C., Bugert, M., Boullosa, B., Eckart de Castilho, R., & Gurevych, I. (2018). *The INCEpTION Platform: Machine-Assisted and Knowledge-Oriented Interactive Annotation*. In *Proceedings of the 27th International Conference on Computational Linguistics: System Demonstrations* (pp. 5–9). Association for Computational Linguistics. Disponible en ligne : <https://aclanthology.org/C18-2002/>. Site officiel INCEpTION : <https://inceptionproject.github.io/>.

Marine Schmitt, Elise Moreau, Mathieu Constant, and Agata Savary. 2019. Démonstrateur en ligne du projet ANR PARSEME-FR sur les expressions polylexicales (On-line demonstrator of the PARSEME-FR project on multiword expressions). In *Actes de la Conférence sur le Traitement Automatique des Langues Naturelles (TALN) PFIA 2019. Volume IV : Démonstrations*, 627–630, Toulouse, France. ATALA. Guide d'annotation PARSEME-fr : <https://parsemefr.lis-lab.fr/doku.php?id=start>.

Savary, A., Ramisch, C., Vincze, V., et al. (2017). *The PARSEME Shared Task on Automatic Identification of Verbal Multiword Expressions*. In *Proceedings of the 13th Workshop on Multiword Expressions (MWE 2017)* (31–47). Association for Computational Linguistics : <https://aclanthology.org/W17-1704.pdf>. Guide d'annotation PARSEME : <https://parsemefr.lislab.fr/parseme-st-guidelines/2.0/?page=home>.

Todirascu, A., François, T., & Cargill, M. (2024). PolylexFLE: A MWE database for French L2 language learners. *ITL - International Journal of Applied Linguistics*, 1-26.

Tutin, A. (2013). Les collocations lexicales : Une relation essentiellement binaire définie par la relation prédicat-argument. *Langages*, 189(1), 47-63. <https://doi.org/10.3917/lang.189.0047>

Zeman, D., et al. (2024). *UniDive: A COST Action on Universality, Diversity and Idiosyncrasy in Language Technology*. In *Proceedings of the 1st Workshop on Multilingual Representation Learning* (pp. 45–50). Association for Computational Linguistics. Disponible en ligne : <https://aclanthology.org/2024.sigul-1.45.pdf>

Guide d'annotation pour les EP verbales

Laboratoire LiLPa UR 1339 (Linguistique, Langues, Parole), Université de Strasbourg

 **ATTENTION** : Il est recommandé de consulter ce guide uniquement après avoir pris connaissance du **guide_gen_EP_STAR-FLE**.

Les expressions polylexicales verbales sont des EP dont la distribution correspond à celle d'un verbe ou d'un groupe verbal. Comme mentionné précédemment, elles se subdivisent en trois catégories : les **idiomes** (expressions idiomatiques), les **collocations opaques** et les **collocations transparentes**.

I. Tests spécifiques aux expressions verbales

- **test de changement morphosyntaxique (test MORPHSYNT)** => Si on change la structure de l'expression (ex. ajout/changement d'un déterminant, possessif, etc.), l'expression devient agrammaticale ou change de sens : *donner un coup de main* => **donner son coup de main* ;
- **test de négation/interrogation (test NEG/QUEST)** : Si la transformation de l'expression en négation ou en interrogation modifie son sens ou rend la combinaison peu acceptable, le test est validé : *tomber dans les pommes* → **ne pas tomber dans les pommes* ;
- **test de passivation (test PASSIV)** : L'expression peut être transformée en construction passive sans changement de sens ni agrammaticalité. Si la passivation est impossible ou fait perdre le sens de l'expression, le test est validé : *prendre la poudre d'escampette* → **la poudre d'escampette a été prise* ;
- **test de compositionnalité (test COMP)** : Si le sens global de l'expression peut être déduit de la somme des sens de ses composants ce test n'est pas validé. Si le sens n'est pas déductible, l'expression est considérée comme idiomatique : *tomber dans les pommes* ≠ *tomber* + *pommes* ;
- **test du verbe vide (test V_VIDE)** => Le verbe est vide de sens propre et le sens est porté par le nom : *faire des progrès* (le verbe *faire* est vide de sens propre, le sens est porté par le nom *progrès*) ;
- **test du nom abstrait ou prédicatif (test N_ABSTR/PRED)** : Ce test vérifie si le nom de l'expression est abstrait ou prédicatif. Un nom abstrait ou prédicatif peut indiquer que le verbe fonctionne comme un verbe support et que l'expression relève d'une collocation. Ainsi, dans *faire des progrès*, le nom prédicatif *progrès* porte l'essentiel du sens.
- **test de la spécificité du verbe (test V_SPEC)** => Le nom est principalement associé à un nombre restreint de verbes, dont le verbe donné : *signer un contrat, essayer un échec* (le verbe *signer* est spécifique à l'acte de contrat et *essayer* à échec) ;

- **test du verbe vicaire (test VIC)** => Il est impossible d'insérer le verbe dans un contexte du type *Paul a fait la fête [et Marc l'en fait]*, où un verbe vicaire (*faire, en faire, le faire, etc.*) devrait pouvoir se substituer au verbe initial tout en maintenant la grammaticalité et le sens de l'énoncé.
- **test de restriction sémantique (test SEM-REST)** : Si la tête de l'expression peut se combiner avec un ensemble restreint de collocatifs appartenant à un même champ sémantique, l'expression relève d'une collocation : *donner un cours, donner une conférence, donner un séminaire*.
- **test de coordination (test COORD)** : Ce test vérifie si l'expression peut être insérée dans une coordination. Si la coordination est impossible ou produit une combinaison étrange, l'expression n'est pas considérée comme une combinaison libre : **Paul économise de l'argent et de la bière*.

II. Tests structuraux pour les expressions verbales qui permettent d'envoyer vers l'arbre de décision correspondant

- si l'EP contient plus d'un verbe => VID (ex. *laisser tomber*) ;
- si l'EP a un sujet lexicalisé => on obtient un VID potentiel (ex. *un petit oiseau m'a dit*) ;
- si l'objet est lexicalisé => on applique les tests de l'arbre de décision pour les EP idiomatiques verbales (*jeter l'éponge* – *éponge* est un élément lexicalisé).



ATTENTION : Par défaut, il faut appliquer d'abord les tests pour les expressions idiomatiques verbales et ensuite pour les collocations.

III. Arbre de décision pour identifier les expressions idiomatiques verbales

Test CRAN : Y a-t-il un mot cranberry ?



Un mot cranberry est un élément figé qui **n'existe pas hors de l'expression**.



Oui → **Expression idiomatique** : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Expression_idiomatique dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEPTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *prendre la poudre d'escampette* (→ *escampette* n'est pas utilisé hors de cette expression).



Non → Passer au test 2.

1. Test MORPH : Modification morphologique → changement de sens / combinaison grammaticale ?



La modification morphologique d'un élément implique un changement du sens.

☒ **Oui** → passer au test 3.

Exemple : *jeter l'éponge* => #*jeter les éponges* (changement de sens).

X Non → Ce n'est pas un **Expression idiomatique** : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*), puis poursuivez avec l'**arbre de décision des collocations verbales**.

2. **Test MORPHSYNT** : Modification morphosyntaxique → changement de sens / combinaison agrammaticale ?

☐ Si on change la structure de l'expression (ex. ajout/changement d'un déterminant, possessif, etc.), l'expression devient agrammaticale ou change de sens.

☒ **Oui** → Passer au test 4.

Exemple : *donner un coup de main* => **donner son coup de main*.

X Non → Ce n'est pas un **Expression idiomatique** : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*), puis poursuivez avec l'**arbre de décision des collocations verbales**.

3. **Test NEG/QUEST** : Transformation en négation ou en interrogation → entraîne-t-elle un changement de sens ou rend-elle la combinaison agrammaticale ?

☐ La transformation syntaxique (passivation, négation, interrogation) est impossible ou change le sens.

☒ **Oui** → Passer au test 5.

Exemple : *tomber dans les pommes* → **ne pas tomber dans les pommes*.

X Non → Ce n'est pas un **Expression idiomatique** : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*), puis poursuivez avec l'**arbre de décision des collocations verbales**.

4. **Test PASSIV** : Transformation en construction passive → entraîne-t-elle un changement de sens ou rend-elle la combinaison agrammaticale ?

☐ La transformation syntaxique (passivation, négation, interrogation) est impossible ou change le sens.

☒ **Oui** → Passer au test 6.

Exemple : *prendre la poudre d'escampette* => #*La poudre d'escampette a été prise*.

X Non → Ce n'est pas un **Expression idiomatique** : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*), puis poursuivez avec l'**arbre de décision des collocations verbales**.

-
5. **Test LEX** : Remplacement d'un des éléments par un synonyme → changement de sens / combinaison agrammaticale ?

☐ Si l'on remplace un élément par un synonyme, le sens change :

☒ **Oui** → passer au test 7.

Exemple : *jeter l'éponge* → *#lancer l'éponge* / *#jeter le torchon* (changement de sens).

X Non → Ce n'est pas un **Expression idiomatique** : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*), puis poursuivez avec l'**arbre de décision des collocations verbales**.

-
6. **Test COMP** : Le sens de l'expression peut-il être déduit de la somme des mots qui la composent (la somme des sens individuels = sens global) ?

☒ **Oui** → Ce n'est pas un **Expression idiomatique** : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*), puis poursuivez avec l'**arbre de décision des collocations verbales**.

Exemple : *faire la fête* (sens compositionnel).

X Non → **Expression idiomatique** : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également **Expression idiomatique** dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEPTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *tomber dans les pommes* ≠ « tomber » + « pommes » (sens non déductible).

Que vous ayez identifié un **Expression idiomatique** ou été redirigé vers l'**arbre de décision des collocations**, n'oubliez pas de renseigner le test ayant conduit à la décision dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*).

☒ Si un **Expression idiomatique** a été identifié, sélectionnez également **Expression idiomatique** dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEPTION, sous l'étiquette « label » (layer : *Relation_EP*).

IV. Tests pour identifier les collocations verbales

Si les arguments du verbe ne sont **pas lexicalisés**, il convient de vérifier si l'expression présente les caractéristiques d'une **collocation**.

Une **collocation verbale** se distingue par :

- **Acceptation des transformations syntaxiques** (passivation, pronominalisation, etc.) ;
- **Série limitée de substitutions lexicales**, où le remplacement du verbe ou du nom entraîne une modification sémantique mais reste possible (*prendre une décision* → *#faire une décision*) ;
- **Sens compositionnel (ou partiellement compositionnel)**, avec une contribution prévisible du verbe et du nom, mais pouvant inclure une nuance supplémentaire dans le cas des **collocations opaques** (*jeter un regard* ≠ *regarder*) ;
- **Sens pouvant être opaque ou transparent**, selon que l'interprétation est directe ou nécessite une inférence (*prendre une décision* vs. *rire jaune*) ;
- **Incompatibilité avec certains contextes syntaxiques** :
 - **Insertion dans un énoncé avec un verbe vicaire impossible** (Test VIC) :
**Paul économise de l'argent, [Marc en fait également]* (NB ! : ✓ *Marc en fait autant*) ;
 - **Coordination** (test COORD) **impossible** avec un autre complément :
**Paul économise de l'argent et de la bière* ;
- **Le verbe est sémantiquement vide** (Test V_VIDE) **ou spécifique** (V_SPEC) :
 - **Verbe support** (vide de sens propre) : **faire** des progrès ;
 - **Verbe métaphorique** : **réaliser** un vœu ;
- **Le nom est abstrait ou prédicatif** (Test N_ABSTR/PRED) :
 - **Nom abstrait** : faire **un rêve** ;
 - **Nom prédicatif** : faire **face** ;

V. Arbre de décision pour identifier les collocations verbales

7. **Test V_VIDE** : Est-ce que le verbe est vide de sens ?

☒ **Oui** → Passer au test 8

Exemple : **faire** des progrès (Le verbe *faire* est vide de sens propre, le sens est porté par le nom *progrès*).

☒ **Non** → Passer au test 9.

8. **Test N_ABSTR/PRED** : Est-ce que le nom est abstrait ou prédicatif ?

➡ Un **nom abstrait** désigne une entité qui ne peut pas être perçue directement par les sens (vue, toucher, ouïe, odorat, goût). Il renvoie à une idée, un concept, une qualité, un état ou une notion qui n'a pas d'existence matérielle concrète.

➡ Le **nom prédicatif** est un nom qui fonctionne de manière proche d'un verbe en exprimant une action, un état ou un procès, souvent en lien avec un verbe support.

☑ **Oui** → C'est une **collocation** : sélectionnez ce test dans la liste déroulante « Test 2 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « tests_ling » (layer : *Span_EP*), puis passez aux tests d'opacité afin d'en déterminer le degré d'opacité.

Exemple : **faire des progrès** (Le verbe *faire* est vide de sens propre, le sens est porté par le nom *progrès*).

✗ **Non** → Passer au test 10.

9. **Test V_SPEC** : Est-ce qu'il y a une association lexicale privilégiée du verbe avec le nom (c'est-à-dire le nom est principalement associé à un nombre restreint de verbes, dont le verbe donné) ?

☑ **Oui** → C'est une **collocation** : sélectionnez ce test dans la liste déroulante « Test 2 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « tests_ling » (layer : *Span_EP*), puis passez aux tests d'opacité afin d'en déterminer le degré d'opacité.

Exemple : **signer un contrat**, **essuyer un échec** (le verbe *signer* est spécifique à l'acte de *contrat* et *essuyer* à *échec*).

✗ **Non** → Passer au test 11.

10. **Test SEM-REST** : La tête de l'expression peut-elle se combiner avec un ensemble restreint de collocatifs appartenant à un même champ sémantique ?

☑ **Oui** → C'est une **collocation** : sélectionnez ce test dans la liste déroulante « Test 2 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « tests_ling » (layer : *Span_EP*), puis passez aux tests d'opacité afin d'en déterminer le degré d'opacité.

Exemple : *donner un cours / une conférence / un séminaire, signer un contrat/un document/une convention*.

✗ **Non** → Passer au test 12.

11. **Test VIC** : Est-il possible d'insérer l'expression dans un énoncé avec un verbe vicair ?

➡ Un **verbe vicair** est un verbe qui assure une fonction **syntactique** plutôt que de porter une signification lexicale propre. Il sert principalement à **supporter une construction prédicative** et

permet souvent la reprise pronominale de l'ensemble du groupe verbal. Ce type de verbe se distingue par le fait qu'il peut être remplacé par un pronom tout en conservant le sens général de l'expression.

☒ **Oui** → Passer au test 13.

☒ **Non** → C'est une **collocation** : sélectionnez ce test dans la liste déroulante « Test 2 » du tableau Excel ou sur la plateforme INCEption, sous l'étiquette « tests_ling » (layer : *Span_EP*), puis passez aux tests d'opacité afin d'en déterminer le degré d'opacité.

Exemple : *prendre son temps* → **Marc en prend aussi*.

12. Test COORD : Est-il possible d'insérer l'expression dans une coordination ?

☒ **Oui** → Combinaison libre, **pas d'annotation – exit**.

Exemple : *Paul mange une pomme et une orange*.

☒ **Non** → C'est une **collocation** : sélectionnez ce test dans la liste déroulante « Test 2 » du tableau Excel ou sur la plateforme INCEption, sous l'étiquette « tests_ling » (layer : *Span_EP*), puis passez aux **tests d'opacité ci-dessous** afin d'en déterminer le degré d'opacité.

Exemple : **Paul économise de l'argent [et de la bière]*.

Une fois l'identification de la collocation confirmée et le test ayant permis de prendre cette décision indiqué, son type final est défini à l'aide de **l'arbre de décision d'opacité**.

VI. Arbre de décision d'opacité

Ces tests permettent de distinguer les **collocations opaques** des **collocations transparentes**. Si **aucun test n'est validé**, l'expression est considérée comme **collocation transparente**. Merci de sélectionner le test validé dans la liste déroulante « Test 3 » du tableau Excel et de l'indiquer dans INCEption dans le champ « test_ling » (couche : *Span_EP*).

 **ATTENTION** : L'opacité peut présenter différents degrés. Ainsi, pour les collocations opaques, veuillez indiquer dans le commentaire le degré d'opacité perçu de l'expression, exprimé en pourcentage.

13. Test SENS : Le sens canonique de tous les constituants est-il conservé, sans modification sémantique induite par leur combinaison ?

☒ **Oui** → Passer au test 15.

Exemple : *prendre une décision* → *prendre* conserve son sens canonique (« effectuer »), *décision* conserve son sens nominal de « produit du fait de décider ».

✗ Non → **Collocation opaque**, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEPTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *rire jaune* → le sens de « jaune » est modifié par sa combinaison avec le verbe « rire ».

14. Sous-tests métaphoriques

La métaphore repose sur un transfert de sens par ressemblance : on parle d'une chose en termes d'une autre, parce qu'elles partagent une propriété ou une image mentale.

15.1. Test META : Le verbe ou la structure verbale repose-t-il sur une analogie implicite entre deux domaines conceptuels (métaphore conceptuelle) ?

☒ Oui → **Collocation opaque**, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEPTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *jeter un froid* → image d'un refroidissement relationnel.

✗ Non → Passer au test 15.2.

15.2. Test REIF : Une action mentale, sociale ou abstraite est-elle représentée comme un objet physique qu'on manipule (réification) ?

☒ Oui → **Collocation opaque**, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEPTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *prendre une décision* → la décision (abstraite) est saisie comme un objet concret.

✗ Non → Passer au test 14.3.

15.3. Test EUF : Euphémisme / atténuation : L'expression adoucit une réalité négative par une formulation indirecte ou vague ?

- ☒ Oui → **Collocation opaque**, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemples : *partir trop tôt* = mourir.

☒ Non → Passer au test 15.4.

15.4. Test CLICHE : L'expression repose-t-elle sur une image stéréotypée, figée dans le discours collectif (journalisme, politique, langage courant...) ?

- ☒ Oui → **Collocation opaque**, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *tirer la sonnette d'alarme* - L'image de la "sonnette d'alarme" évoque une situation de **danger imminent**, et "tirer" cette sonnette est devenue une **métaphore figée** pour alerter publiquement.

☒ Non → Passer au test 16.

16. Sous-tests métonymiques

Une métonymie se produit quand on remplace une idée par une autre qui lui est liée par une relation logique (comme la cause, l'effet, le contenant, le contenu, la partie pour le tout, etc.).

16.1. Test SYNE : Synecdoque (partie ↔ tout). Le verbe s'applique-t-il à une partie pour désigner un tout (ou inversement) ?

- ☒ Oui → **Collocation opaque**, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *avoir la main lourde* → "main" = personne, action globale.

☒ Non → Passer au test 16.2.

16.2. Test CAUSE : Cause Effet. L'expression exprime-t-elle un effet visible, tout en désignant une cause sous-jacente ?

☒ Oui → **Collocation opaque**, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *crever de faim* → effet dramatique pour désigner la faim.

☒ Non → Passer au test 16.3.

16.3. Test OBJET : Contenant ↔ contenu. Le complément désigne-t-il un objet, mais réfère en réalité à son contenu ?

☒ Oui → **Collocation opaque**, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *boire un verre* → "verre" = boisson.

☒ Non → Passer au test 16.4.

16.4. Test LIEU : Lieu → activité / production : Le verbe est-il appliqué à un lieu qui désigne une activité typique de ce lieu ?

☒ Oui → **Collocation opaque**, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *envahir l'Élysée* → « l'Élysée » = le pouvoir politique (activité politique).

☒ Non → Passer au test 16.5.

16.5. Test COUL — Couleur → entité / effet : Une couleur dans l'expression désigne-t-elle une notion métonymique (état, émotion, etc.) ?

- ☒ Oui → **Collocation opaque**, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *boire du rouge* → « rouge » = vin rouge.

- ☒ Non → Passer au test 16.6.

16.6. Test AUTEUR : Auteur → œuvre : Le verbe est-il appliqué à un auteur pour désigner son œuvre ?

- ☒ Oui → **Collocation opaque**, sélectionnez ce test avec la réponse « OUI » dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *lire Balzac* → "Balzac" = ses œuvres.

- ☒ Non → **Collocation transparente**, sélectionnez ce test avec la réponse « NON » dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Veuillez renseigner **le test ayant permis d'identifier le type d'expression** dans la liste déroulante « **Test 3** » du tableau Excel, ou sur la plateforme **INCEpTION**, sous l'étiquette « **tests_ling** » (layer : *Span_EP*).

Indiquez également le **type final de l'EP** :

- dans la liste déroulante « **Type de l'expression polylexicale** » du tableau Excel
- ou sous l'étiquette « **label** » du layer *Relation_EP* sur INCEpTION.


◇ Dans les deux cas, vous pouvez utiliser l'étiquette « **Autre (Expliquer dans les commentaires)** » pour les expressions qui ne relèvent ni des expressions libres, ni d'un des types d'expressions figées proposés dans la liste (ex. : **entités nommées**).

📌 Lorsque vous sélectionnez cette étiquette, l'ajout d'un commentaire est **obligatoire**.

 **ATTENTION :** En cas d'hésitation quant à la catégorie finale de l'expression, vous pouvez indiquer votre **degré de certitude** dans le commentaire.

VII. Schéma de l'arbre de décision verbal complet

Arbre de décision simplifié — EP verbales



Lecture : Oui = test validé · Non = passer à l'étape suivante.
Le guide recommande de tester d'abord l'hypothèse idiomatique, puis les collocations.

Guide d'annotation pour les EP nominales

Laboratoire LiLPa UR 1339 (Linguistique, Langues, Parole), Université de Strasbourg

 **ATTENTION** : Il est recommandé de consulter ce guide uniquement après avoir pris connaissance du guide_gen_EP_STAR-FLE.

Les expressions polylexicales nominales (EP nominales) sont des EP dont la distribution correspond à celle d'un syntagme nominal. Comme mentionné précédemment, elles se répartissent en trois catégories : les **expressions idiomatiques**, les **collocations opaques** et les **collocations transparentes**.

I. Tests spécifiques aux expressions polylexicales nominales

- 1) Parmi les tests appliqués pour identifier les expressions polylexicales nominales, un test formel porte sur l'organisation interne de l'expression : **le test de l'irrégularité structurelle ou distributionnelle (test IRREG)**.

Ce test repose sur l'idée qu'une expression nominale figée peut présenter une structure qui ne correspond pas au fonctionnement ordinaire d'un syntagme nominal en français. L'irrégularité peut concerner soit la structure globale de l'expression, soit la distribution d'un ou de plusieurs de ses composants. Pour le vérifier, on se demande si l'expression peut être analysée comme une unité nominale régulière et si chacun de ses éléments occupe une position syntaxique attendue.

- Par exemple, dans l'expression *va-et-vient*, l'unité fonctionne comme un nom, mais sa structure interne repose sur deux formes verbales coordonnées. Elle ne correspond donc pas à la structure régulière d'un syntagme nominal, ce qui révèle une irrégularité structurelle.
- À l'inverse, une expression comme *voiture électrique* présente une structure régulière de type *nom + adjectif*, dans laquelle chaque composant occupe une position attendue. Le test IRREG n'est donc pas validé.

- 2) Parmi les tests appliqués pour identifier les expressions idiomatiques nominales, un test sémantique spécifique se distingue : **le test de l'hyponymie (test ID)**.

Ce test repose sur l'idée que, dans une expression idiomatique, le noyau sémantique de l'expression ne peut pas être mis en relation avec un hyperonyme approprié. Pour le vérifier, on reformule l'expression sous la forme interrogative suivante : « Est-ce un type de X ? », où X correspond à un mot susceptible d'être un hyperonyme du noyau apparent de l'expression.

- Par exemple, dans l'expression *cordon bleu* (au sens de « bon cuisinier »), il n'est pas pertinent de dire qu'il s'agit d'un *type de cordon*, ce qui révèle un décalage sémantique et donc un caractère **idiomatique**.
- À l'inverse, l'expression *célibataire endurci* peut être interprétée comme un *type de célibataire*, renforçant l'idée de continuité ou d'intensification de l'état de célibat. La relation d'hyponymie est donc ici valide, ce qui indique que l'expression n'est pas idiomatique, mais plutôt **compositionnelle**.

II. Arbre de décision pour identifier les expressions polylexicales nominales

1. Test CRAN : Présence d'un mot cranberry ?

☐ Un mot cranberry est un élément figé qui n'existe pas hors de l'expression.

☒ Oui → C'est une **Expression idiomatique**, exit. Merci d'indiquer ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (couche : *Span_EP*).

Exemple : **statu quo**, **us** et coutumes.

☒ Non → Passer au test 2.

2. Test IRREG : L'expression présente-t-elle une structure irrégulière pour une expression nominale, ou bien un ou plusieurs de ses composants présentent-ils une distribution irrégulière pour une unité nominale ?

☒ Oui → C'est une **Expression idiomatique**, exit. Merci d'indiquer ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (couche : *Span_EP*).

Exemple : *porte-monnaie* (« porte » a une distribution verbale).

☒ Non → Passer au test 3.

3. Test MORPH : Modification morphologique → changement de sens / combinaison agrammaticale ?

☒ Oui → C'est une EP : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (couche : *Span_EP*), afin de l'annoter. Ensuite, passez au test 7.

Exemple : garde **du** corps → #garde **des** corps.

☒ Non → Passer au test 4.

4. Test SYNT : Modification syntaxique (y compris changement de l'ordre des mots) → changement de sens / combinaison agrammaticale ?

☒ Oui → C'est une EP : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (couche : *Span_EP*), afin de l'annoter. Ensuite, passez au test 7.

Exemple : conseil régional → *conseil de (la) région.

✗ Non → passer au test 5.

Exemple : *produit régional* → *produit de la région*.

5. **Test LEX** : Remplacement d'un des éléments par un synonyme → changement de sens / combinaison agrammaticale ?

☒ Oui → C'est une EP : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (couche : Span_EP), afin de l'annoter. Ensuite, passez au test 7.

Exemple : **eau** de vie → **#boisson** de vie.

✗ Non → Passer au test 6.

6. **Test MODIF** : Insertion d'un modifieur portant sur l'un des constituants (et non sur l'expression entière) → un changement de sens / combinaison agrammaticale ?

☒ Oui → C'est une EP : sélectionnez ce test dans la liste déroulante « Test 1 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (couche : Span_EP), afin de l'annoter. Ensuite, passez au test 7.

Exemple : étoile [**très/*absolument*] filante.

✗ Non → C'est une expression libre, **exit**.

Une fois l'EP nominale identifiée, n'oubliez pas de sélectionner le test qui a permis son identification dans la liste déroulante sous l'étiquette « tests_ling » (layer utilisé : Span_EP) dans INCEpTION, puis passez à l'arbre de décision suivant afin de déterminer sa sous-catégorie.

7. **Test ID** : L'expression peut-elle être reformulée en utilisant un hyperonyme ?

☒ Oui → Passer au test 8.

Exemple : *célibataire endurci* est un « célibataire ».

✗ Non → **Expression idiomatique**, exit. Merci d'indiquer ce test dans la liste déroulante « Test 2 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (couche : Span_EP).

Exemple : *cordon bleu* n'est pas un « cordon » (« cord »).

Tests d'opacité sémantique

Ces tests permettent de distinguer les **collocations opaques** des **collocations transparentes**. Si **aucun test n'est validé**, l'expression est considérée comme **collocation transparente**. Merci de sélectionner le test validé dans la liste déroulante « Test 3 » du tableau Excel et de l'indiquer dans INCEPTION dans le champ « test_ling » (couche : Span_EP).

 **ATTENTION** : L'opacité peut présenter différents degrés. Ainsi, pour les collocations opaques, veuillez indiquer dans le commentaire le degré d'opacité perçu de l'expression, exprimé en pourcentage.

8. Test SENS : Le sens canonique de tous les constituants est-il conservé, sans modification sémantique induite par leur combinaison ?

☒ Oui → Passer au test 9.

☒ Non → **collocation opaque**, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEPTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *célibataire* **endurci** → le sens de « endurci » est modifié par sa combinaison avec le nom « célibataire ».

9. Sous-tests métaphoriques

La métaphore repose sur un transfert de sens par ressemblance : on parle d'une chose en termes d'une autre, parce qu'elles partagent une propriété ou une image mentale.

9.1. Test META : L'expression repose-t-elle sur une **analogie implicite** entre deux domaines (concret ↔ abstrait, physique ↔ émotionnel, etc.) ?

☒ Oui → Collocation opaque, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEPTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *célibataire* *endurci* → le célibat est comparé à un matériau qui se durcit.

☒ Non → Passer au test 9.2.

9.2. Test REIF : Réification – un concept abstrait est-il représenté comme une entité concrète ou mesurable ?

- ☒ Oui → Collocation opaque, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEPTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *poids des mots* → les mots sont conceptualisés comme des objets pesants.

- ☒ Non → Passer au test 9.3.
-

9.3. Test EUF : Euphémisme / Atténuation : L'expression adoucie-t-elle une réalité sociale, physique ou morale par une formulation indirecte ?

- ☒ Oui → Collocation opaque, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEPTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *personne en situation de précarité* → formulation indirecte pour désigner la pauvreté.

- ☒ Non → Passer au test 9.4.
-

9.4. Test CLICHE : L'expression repose-t-elle sur une image stéréotypée, figée dans le discours collectif (journalisme, politique, langage courant...) ?

- ☒ Oui → Collocation opaque, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEPTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEPTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *course contre la montre* → image figée de la lutte contre le temps.

- ☒ Non → Passer au test 10
-

10. Sous-tests de métonymie

Une métonymie se produit quand on remplace une idée par une autre qui lui est liée par une relation logique (comme la cause, l'effet, le contenant, le contenu, la partie pour le tout, etc.).

10.1. Test SYNE : Synecdoque – une partie désigne-t-elle le tout, ou inversement ?

- ☒ Oui → Collocation opaque, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *tête blonde* → "tête" = enfant (partie pour le tout).

- ☒ Non → Passer au test 10.2.
-

10.2. Test CAUSE : Cause / Effet : L'un des éléments exprime-t-il un effet visible au lieu d'une cause ou d'un état sous-jacent ?

- ☒ Oui → Collocation opaque, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *coup de fatigue* → le "coup" désigne une manifestation soudaine de fatigue.

- ☒ Non → Passer au test 10.3.
-

10.3. Test COUL : Couleur → produit ou propriété : Une couleur est-elle utilisée pour désigner un produit ou un contenu associé ?

- ☒ Oui → Collocation opaque, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *verre de rouge* → "rouge" = vin rouge.

- ☒ Non → Passer au test 10.4.
-

10.4. Test AUTEUR : Auteur → œuvre : Le nom d'un auteur désigne-t-il une œuvre qu'il a produite ?

- ☒ Oui → Collocation opaque, sélectionnez ce test dans la liste déroulante « Test 3 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette « test_ling » (layer : *Span_EP*). Indiquez également Collocation_opaque dans la liste déroulante « Type d'expression polylexicale » du tableau Excel ou sur INCEpTION, sous l'étiquette « label » (layer : *Relation_EP*), afin d'annoter le type d'expression.

Exemple : *lecture de Balzac* → "Balzac" = ses romans.

✗ Non → Collocation transparente, exit. Merci d'indiquer ce test avec la réponse (OUI/NON) dans la liste déroulante « Test 2 » du tableau Excel ou sur la plateforme INCEpTION, sous l'étiquette test_ling (couche : Span_EP).

Veuillez renseigner **le test ayant permis d'identifier le type d'expression** dans la liste déroulante « **Test 3** » du tableau Excel, ou sur la plateforme **INCEpTION**, sous l'étiquette « **tests_ling** » (layer : *Span_EP*).

Indiquez également le **type final de l'EP** :

- dans la liste déroulante « **Type de l'expression polylexicale** » du tableau Excel
- ou sous l'étiquette « **label** » du layer *Relation_EP* sur INCEpTION.


◇ Dans les deux cas, vous pouvez utiliser l'étiquette « **Autre (Expliquer dans les commentaires)** » pour les expressions qui ne relèvent ni des expressions libres, ni d'un des types d'expressions figées proposés dans la liste (ex. : **entités nommées**).

👉 Lorsque vous sélectionnez cette étiquette, l'ajout d'un commentaire est **obligatoire**.

📌 **ATTENTION** : En cas d'hésitation quant à la catégorie finale de l'expression, vous pouvez indiquer votre **degré de certitude** dans le commentaire.

III. Schéma de l'arbre de décision nominal complet

Arbre de décision simplifié — EP nominales



Lecture : Oui = test validé · Non = passer à l'étape suivante